LABORATORIO DE SIMULACIÓN COMPUTACIONAL

UNIDAD ACADEMICA:	Ingeniería de Sistemas
CURSO:	Simulación Computacional
PRACTICA Nº 04:	Análisis de datos de entrada y ajuste de datos a distribuciones de probabilidad

1. OBJETIVOS

- Introducir al análisis de datos de entrada en un estudio de simulación a partir de muestras de datos asociadas a procesos o fenomenos del sistema objeto de estudio.
- Identificar si un conjunto de valores de una muesta de datos asociados a algun proceso o fenomeno se puede asociar a una variable aleatoria independiente (no correlacionada), estacionaria.
- Evaluar la bondad de ajuste (*godness of fit*) de diferentes distribuciones de probabilidad a un conjunto de datos.
- Seleccionar la distribución de probabilidad más apropiada y con mejor ajuste dado un conjunto de datos para su posterior modelado en un estudio de simulación.

2. CONSULTA PREVIA

- ¿En qué consiste la estadística descriptiva?
- ¿Qué son la asimetria estadística (*skewness*), la curtosis y los percentiles?
- ¿Qué significa y en qué consiste el supuesto que un conjunto de variables aleatorias sean IID?
- ¿En qué consiste un proceso estocástico estacionario?
- ¿En qué consiste un proceso estocástico correlacionado?

3. FUNDAMENTO TEORICO

La fundamentación teórica y marco conceptual necesarios para el desarrollo de la práctica se encuentra en la presentación realizada en clase *3. Input Data Analysis*, y en el Capítulo 3 del libro [Banks98], en especial de la siguientes secciones:

3.1. Nature of simulation input
3.2. Roots of simulation input modeling
3.3. Data collection
3.4. Practical methods for testing assumptions
3.4.1. Methods for Assessing Independence
3.4.2. Methods for Assessing Stability of Distribution
3.5. Univariate IID case with data
3.5.1. Alternative Distribution Forms
3.5.2. Recommended Strategy for Selecting the Distribution Form
3.5.3. Practical Application of Standard Distributions and Flexible Families
3.5.4. Practical Application of Empirical Distributions
3.6. Approaches for handling the non-IID case
3.7. What to do when no data are available

Presentación (Diapositivas):

- *3. Input Data Analysis*
  https://docs.google.com/presentation/d/1YDKd2TBHKe-z8Hm_98NySwUQ76yGIVSX3Yv8-DR2174/htmlpresent

Capítulo de libro:

- Capítulo 3 del libro [Banks98]
  https://drive.google.com/file/d/1ZP_RNWbCE1BjeHmWsgdhJgRTmYbw6V0T/view

LABORATORIO DE SIMULACIÓN COMPUTACIONAL

4. EQUIPOS, MATERIALES Y REACTIVOS

Equipos	Materiales	Sustancias y/o Reactivos
Equipo de cómputo, computador personal, portatil o estación de trabajo, con acceso a Internet.	Capítulo 3 del libro [Banks98] Ajuste y selección de distribuciones con Python [*Amat2021*] Google Colaboratory (Colab) URL: https://colab.research.google.com/ con acceso desde la cuenta institucional de Unillanos (usuario@unillanos.edu.co) Notebooks de Jupyter de ejemplo en Google Colab para análisis de datos de entrada y diferentes ejemplos de ajustes de curvas a distribuciones de probabilidad: - Example. Input Data Analysis.ipynb https://colab.research.google.com/drive/1KcKQskocWvIT-Ff7fMd91Irs9yTYC9yO?usp=sharing - Fitting data to a distribution.ipynb https://colab.research.google.com/drive/1ENmw-ALyR1KhrR_YrpPQHl3FoZF-qTFr?usp=sharing - Distribution fitting with scipy.ipynb https://colab.research.google.com/drive/1szIdyEIFhbkzurqYj1CCmW-Q9nPvtJ7r?usp=sharing - Fit data to distributions with SciPy.ipynb https://colab.research.google.com/drive/1RT8EBR1I1uGrbWpAiIL56w-y2Lrk6Veo?usp=sharing - Fitting Niño data to a distribution.ipynb https://colab.research.google.com/drive/1gOtxzo8kzAdcXNUwqMiDWbvjiDSldJj5?usp=sharing	N/A

5. PROCEDIMIENTO O METODOLOGÍA

5.1. CONJUNTO DE DATOS

Descargue los siguientes conjuntos de datos:

- dataset-A.txt (https://drive.google.com/file/d/1xYqg1BCxDQH542_Njz0s7tzay6dIG_VO/view?usp=sharing)
- dataset-B.txt (https://drive.google.com/file/d/1W-pHCurCQFaJ_ydv5BDYsWDxg2-2dxZX/view?usp=sharing)
- dataset-C.txt (https://drive.google.com/file/d/10B8Y6i1H_1J8cFeLoufWTVTtzthYSXj/view?usp=sharing)
- dataset-D.txt (https://drive.google.com/file/d/1LysY3NL4fFamvChMtPQNrKaXaNMfN_44/view?usp=sharing)

Realice un primer análisis preliminar de los datos usando estadistica descriptiva, para ello por cada conjunto de datos calcule lo siguiente:

a) No. de observaciones. (tamaño de la muestra)
b) Mínimo
c) Máximo
d) Media
e) Varianza
f) Desviación estandar
g) Percentiles de 25% (Q1), 50% (Q2 o mediana) y 75% (Q3)

LABORATORIO DE SIMULACIÓN COMPUTACIONAL

Presente los valores calculados en una tabla de la siguiente forma:

Tabla 1. Descripción estadística de los conjuntos de datos A, B, C y D.

Medida estadística	Dataset A	Dataset B	Dataset C	Dataset D
Tamaño de la muestra				
Mínimo				
Máximo				
Media				
Varianza				
Desviación estandar				
Percentil 25% (Q1)				
Percentil 50% (Q2 o mediana)				
Percentil 75% (Q3)				

Grafíque en un histograma la distribución de cada uno de los conjuntos de datos con un número de particiones o *bins* igual a 20 para visualizarlos todos como subgraficas como en esta figura de ejemplo:

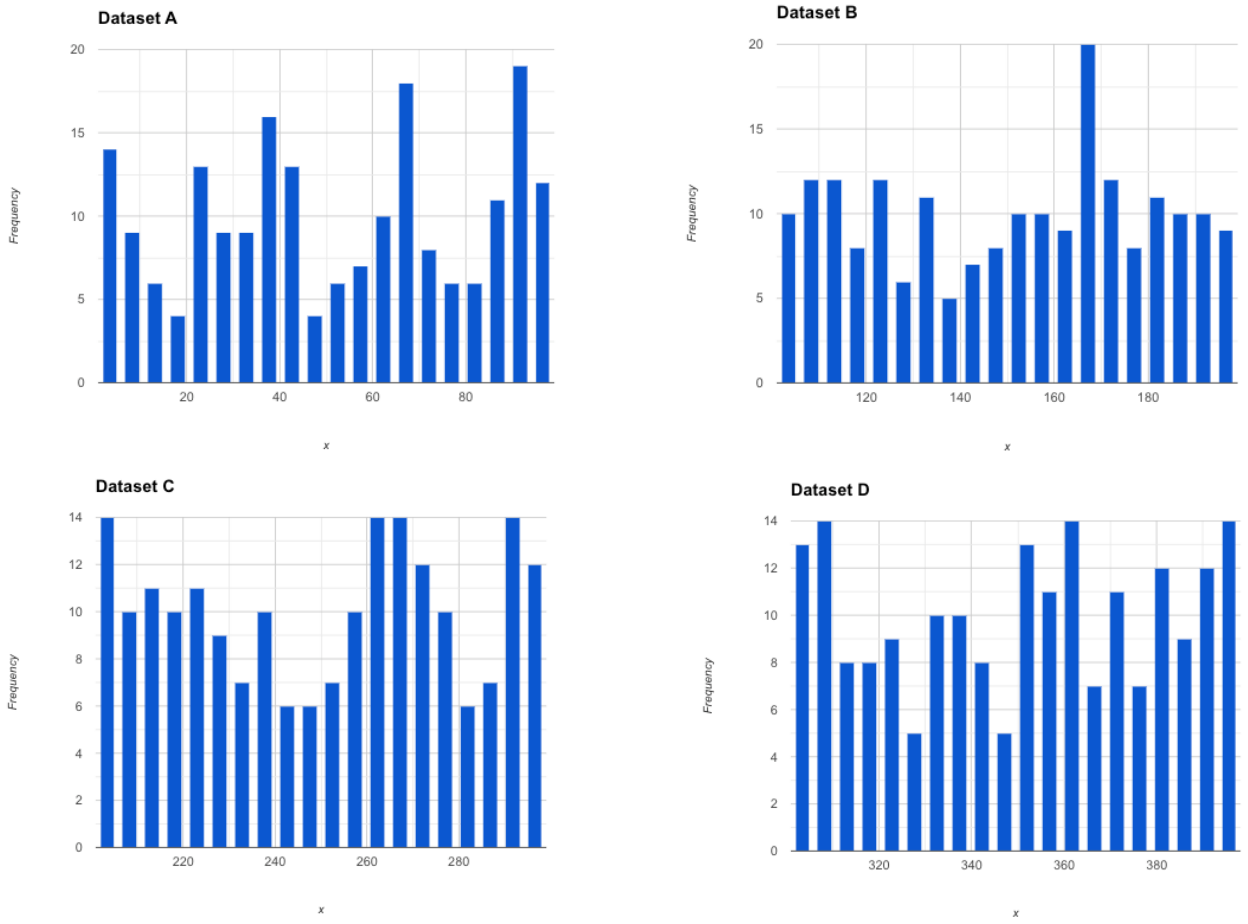


Figura 1. Histogramas de distribuciones de los conjuntos de datos A, B, C y D.

¿Qué puede analizar de las medidas de estadística descriptiva y los histogramas para los diferentes conjuntos de datos?

LABORATORIO DE SIMULACIÓN COMPUTACIONAL

5.2. ANÁLISIS DE DATOS DE ENTRADA

Tomando en cuenta el Notebook de ejemplo de análisis de datos de entrada (*Example. Input Data Analysis.ipynb*) y tomando en cuenta los cuatro conjuntos de datos (dataset-A.txt, dataset-B.txt, dataset-C.txt, dataset-D.txt) de las muestras tomadas de cuatro procesos estocásticos, realice las gráficas de:

a. Correlaciones de retraso estimadas (*Estimated lag correlations*)
b. Diagrama de dispersión (*Scatter diagram*)
c. Patrón de hora de llegada (*Arrival time pattern*)
d. Conteo de llegadas vs intervalos (*Arrival counts vs intervals*)
e. Gráfico de media móvil (*Moving average plot*)

De acuerdo con las gráficas generadas de la muestra de los conjuntos de datos ¿Qué puede determinar de cada conjunto de datos en relación con la evaluación de supuestos de independencia o correlación y estabilidad de la secuencia de valores?

5.3. AJUSTE DE CURVAS

Tomando en cuenta como referencia el tutorial de [Amat2021] o los diferentes Notebook de ejemplo para el ajuste de curvas, desarrolle un archivo Notebook independiente para realizar el ajuste de curvas para evaluar la bondad de ajuste (*godness of fit*) de los cuatro conjuntos de datos con las siguientes cuatro (4) distribuciones de probabilidad:

a. Exponencial
b. Lognormal
c. Normal
d. Gamma
e. Beta

así como otras cuatro (4) distribuciones de probabilidad de su selección adicionales, para un total de ocho (8) distribuciones de probabilidad.

Evalue el ajuste de bondad de ajuste (*godness of fit*) usando como criterios las siguientes métricas:

a. Suma de errores cuadráticos (*Sum of Squared Errors* – SSE)
b. Criterio de información de Akaike (*Akaike Information Criterion* – AIC)
c. Criterio de información Bayesiano (*Bayesian Information Criterion* – BIC)

Por cada conjunto de datos realice el ajuste de datos evaluando la bondad del ajuste (*godness of fit*) con las ocho (8) distribuciones de probabilidad y elabore la siguiente tabla por conjunto de datos: (A, B, C y D)

Tabla #. Bondad de ajuste para el conjunto de datos X.

Distribución de probabilidad	Parámetros	SSE	AIC	BIC
Exponencial				
Lognormal				
Normal				
Gamma				
Beta				
Distribución_1				
Distribución_2				
Distribución_3				
Distribución_4				

Por cada conjunto de datos, y tomando en cuenta las medidas de bondad de ajuste SSE, AIC y BIC, identifique las tres (3) mejores distribuciones de probabilidad con sus respectivos parámetros y en una misma figura grafique el histograma del conjunto de datos con cada una de las tres (3) distribuciones de probabilidad con el mejor ajuste.

¿Cuál de las tres distribuciones de probabilidad con mejor ajuste seleccionaría Ud. por cada conjunto de datos? ¿Porqué? Explique brevemente.

6. RESULTADOS

Entregar los resultados en un informe en PDF con cada una de las secciones de este laboratorio, respondiendo la consulta previa (Sección 2) y el desarrollo detallado de cada paso de las secciones 5.1, 5.2 y 5.3 con las preguntas respondidas, con las imágenes, gráficas o capturas de pantalla y tablas que sean necesarias, así como con los archivos adjuntos .ipynb usados con los datos registrados y ejecutados.

7. BIBLIOGRAFIA

[Banks98] Jerry Banks. Handbook of Simulation: Principles, Methodology, Advances, Applications, and Practice. John Wiley & Sons, Inc., 1998

[Amat2021] Ajuste y selección de distribuciones con Python por Joaquín Amat Rodrigo, disponible con licencia CC BY-NC-SA 4.0 en https://www.cienciadedatos.net/documentos/pystats01-ajuste-distribuciones-python.html . https://doi.org/10.5281/zenodo.10006330