Práctica No. 5:

Análisis de datos de entrada y ajuste de datos a distribuciones de probabilidad

J. Gregorio Delgado[1]

1. Código: 160005010, Ingeniería de Sistemas.

Facultad de Ciencias Básicas e Ingenierías. Programa de Ingeniería de Sistemas.

Fecha: Octubre de 2026

Resumen

Se analizaron cuatro muestras de 200 observaciones (A, B, C y D) de procesos estocásticos, interpretadas como tiempos entre llegadas, siguiendo el capítulo 3 de Banks [1]. Primero se describieron con estadística descriptiva e histogramas. Después se evaluaron los supuestos de independencia y estabilidad con correlaciones de retraso, diagramas de dispersión, patrón de llegadas, conteos por intervalo y media móvil, complementados con pruebas de Ljung-Box, rachas, Spearman y Kruskal-Wallis. Por último, se ajustaron nueve distribuciones por máxima verosimilitud y se compararon con SSE, AIC y BIC. B y D son IID y se modelan con una Exponencial de media 0,205 y una Lognormal (σ = 1,019, escala 1,273). A es estacionario pero autocorrelacionado ($r_1 = 0{,}52$): su marginal es aproximadamente Normal y se reproduce con un AR(1) de innovaciones uniformes. C no es estacionario: su media crece linealmente con el orden de observación y, al normalizar por esa tendencia, los datos son IID exponenciales. La Gamma que mejor ajusta los datos agregados de C es solo un efecto de mezclar escalas.

Palabras clave — análisis de datos de entrada, IID, autocorrelación, estacionariedad, bondad de ajuste, máxima verosimilitud, AIC, BIC.

1. Objetivos

- Introducir el análisis de datos de entrada en un estudio de simulación a partir de muestras de datos de procesos o fenómenos del sistema objeto de estudio.
- Identificar si los valores de una muestra se pueden asociar a una variable aleatoria independiente (no correlacionada) y estacionaria.
- Evaluar la bondad de ajuste de diferentes distribuciones de probabilidad a un conjunto de datos.
- Seleccionar la distribución de probabilidad más apropiada y con mejor ajuste para su posterior modelado en un estudio de simulación.

2. Consulta previa

1. **Estadística descriptiva.** Es la rama de la estadística que resume y presenta un conjunto de datos sin hacer inferencias sobre la población. Usa medidas de tendencia central (media,

mediana, moda), de dispersión (rango, varianza, desviación estándar, rango intercuartílico, coeficiente de variación), de posición (percentiles y cuartiles) y de forma (asimetría y curtosis), además de tablas de frecuencia y gráficas como el histograma o el diagrama de caja. En simulación es el primer paso para sugerir familias de distribuciones candidatas [1, Sec. 3.5].

2. **Asimetría, curtosis y percentiles.** La *asimetría* (*skewness*), $g_1 = \frac{1}{n}\sum(x_i - \bar{x})^3/s^3$, mide la falta de simetría: vale 0 en una distribución simétrica, es positiva si la cola derecha es más larga (la media supera a la mediana) y negativa en el caso contrario. La *curtosis*, $g_2 = \frac{1}{n}\sum(x_i-\bar{x})^4/s^4 - 3$ (en exceso respecto a la normal), mide el peso de las colas: vale 0 para la normal, es positiva en distribuciones con colas pesadas y negativa en distribuciones de colas cortas, como la uniforme $(-1{,}2)$. El *percentil* p es el valor por debajo del cual queda el $p\,\%$ de los datos. Los cuartiles Q_1, Q_2 (mediana) y Q_3 son los percentiles 25, 50 y 75, y $Q_3 - Q_1$ es una medida de dispersión robusta.

3. **Supuesto IID.** Un conjunto de variables aleatorias $X_1, \ldots, X_n$ es IID (*independientes e idénticamente distribuidas*) si el valor de cualquiera no aporta información sobre los demás (independencia) y todas tienen la misma distribución (estabilidad). Es el supuesto que permite resumir una muestra con una sola distribución univariada y generar en la simulación valores independientes de ella. Si no se cumple, el modelo de entrada debe incluir la dependencia o el cambio en el tiempo [1, Sec. 3.4 y 3.6].

4. **Proceso estocástico estacionario.** Un proceso $\{X_t\}$ es estrictamente estacionario si la distribución conjunta de $(X_{t_1}, \ldots, X_{t_k})$ no cambia al desplazar todos los instantes en el tiempo. En sentido débil (o de covarianza) basta con que la media y la varianza sean constantes y que $\mathrm{Cov}(X_t, X_{t+k})$ dependa solo del retraso k. Una tendencia en la media, un cambio de varianza o un salto de nivel hacen que el proceso no sea estacionario.

5. **Proceso estocástico correlacionado.** Es aquel en que las observaciones están relacionadas entre sí: la autocorrelación $\rho_k = \mathrm{Corr}(X_t, X_{t+k})$ es distinta de cero para algún $k \geq 1$. Con correlación positiva, a valores altos les siguen valores altos (por ejemplo, tiempos de servicio de un operario que se cansa). Un proceso así puede ser estacionario, como el AR(1) $X_t = \mu + \varphi(X_{t-1} - \mu) + \varepsilon_t$ con $|\varphi| < 1$, cuyo $\rho_k = \varphi^k$ decae geométricamente.

3. Fundamento teórico

3.1. Evaluación de la independencia

La correlación de retraso k estimada con los $n - k$ pares (x_i, x_{i+k}) es

$$\hat{\rho}_k = \frac{\sum_{i=1}^{n-k}(x_i - \bar{x})(x_{i+k} - \bar{x})}{\sqrt{\sum_{i=1}^{n-k}(x_i - \bar{x})^2 \sum_{i=1}^{n-k}(x_{i+k} - \bar{x})^2}}. \tag{1}$$

Para datos independientes, $\hat{\rho}_k$ es aproximadamente $N(0, 1/n)$, así que se espera que el 95 % de los valores quede en la banda $\pm 2/\sqrt{n} = \pm 0{,}141$ para $n = 200$. El diagrama de dispersión de (x_k, x_{k+1}) complementa la gráfica: si los datos son independientes, la nube no tiene inclinación [1, Sec. 3.4.1]. Como prueba conjunta se usa el estadístico de Ljung-Box $Q = n(n+2)\sum_{k=1}^{m} \hat{\rho}_k^2/(n-k) \sim \chi^2_m$, y como prueba no paramétrica, el número de rachas por encima y por debajo de la mediana.

3.2. Evaluación de la estabilidad

Si los datos son tiempos entre llegadas, los instantes de llegada son $t_j = \sum_{i \le j} x_i$. El *patrón de llegadas* grafica la proporción de llegadas antes de T frente a T: con tasa constante es una recta. Los *conteos por intervalo* dividen $[0, t_n]$ en intervalos iguales y cuentan las llegadas en cada uno. La *media móvil* $y_k = \frac{1}{2W+1} \sum_{j=-W}^{W} x_{k+j}$ suaviza la serie para revelar tendencias o saltos [1, Sec. 3.4.2]. Se complementan con la correlación de Spearman entre el valor y su posición (tendencia monótona) y con la prueba de Kruskal-Wallis entre cuatro bloques consecutivos de 50 datos.

3.3. Ajuste y criterios de bondad de ajuste

Los parámetros $\hat{\theta}$ de cada distribución se estiman por máxima verosimilitud, maximizando $\ln L(\theta) = \sum_i \ln f(x_i; \theta)$. Con k parámetros libres y n datos:

$$\mathrm{SSE} = \sum_{j=1}^{20} \big(\hat{f}_j - f(c_j; \hat{\theta})\big)^2, \qquad \mathrm{AIC} = 2k - 2\ln L(\hat{\theta}), \qquad \mathrm{BIC} = k \ln n - 2 \ln L(\hat{\theta}), \tag{2}$$

donde $\hat{f}_j$ es la densidad del histograma en el bin j y c_j su centro. En los tres criterios, un valor menor indica mejor ajuste. El SSE depende de los bins y de la escala de la variable, mientras que AIC y BIC penalizan la complejidad; el BIC lo hace más cuando $n \ge 8$. Una diferencia de AIC menor que 2 se considera un empate práctico. Cuando un modelo está anidado en otro (la Exponencial es la Weibull con $c = 1$ y la Gamma con $a = 1$), la razón de verosimilitudes $2(\ln L_1 - \ln L_0) \sim \chi^2_1$ indica si el parámetro extra está justificado. Por último, los gráficos P-P y Q-Q comparan $F_n(x_{(k)}) = (k - \frac{1}{2})/n$ con el modelo: el P-P es más sensible en el centro y el Q-Q en las colas [1, Sec. 3.5].

4. Equipos, materiales y herramientas

Cuadro 1: Recursos utilizados.

Recurso	Descripción
Equipo de cómputo	Computador personal.
Python 3.12	Notebooks `Lab_Input_Data_Analysis.ipynb` (secciones 5.1 y 5.2) y `Lab_Ajuste_Curvas.ipynb` (sección 5.3).
Bibliotecas	NumPy, pandas, SciPy 1.18 (`scipy.stats`) [3] y Matplotlib.
Datos	`dataset-A.txt`, `dataset-B.txt`, `dataset-C.txt` y `dataset-D.txt`.
Referencias	Capítulo 3 de Banks [1] y el tutorial de Amat Rodrigo [2].

5. Procedimiento o metodología

5.1. Conjunto de datos y estadística descriptiva

Se cargaron los cuatro archivos (200 valores cada uno, en el orden en que se observaron) y se calcularon las medidas pedidas por la guía con la varianza muestral ($n - 1$). Se agregaron la

asimetría, la curtosis en exceso y el coeficiente de variación $CV = s/\bar{x}$, útiles para comparar con las familias candidatas: $CV = 1$ en la exponencial, $CV < 1$ en una Gamma con $a > 1$ y $CV > 1$ en una Gamma con $a < 1$. Se graficaron los histogramas con 20 bins.

5.2. Análisis de datos de entrada

Se reescribieron las gráficas del notebook *Example. Input Data Analysis* como funciones sin variables globales y se aplicaron a cada conjunto: valores frente al orden, correlaciones de retraso hasta el lag 20 con la banda $\pm 2/\sqrt{n}$, diagrama de dispersión, patrón de llegadas, conteos en 40 intervalos y media móvil con $W = 10$ (ventana de 21 datos). La media móvil se acompaña de la media global y de bandas a ± 3 desviaciones estándar de la propia media móvil; se sombrean los W puntos de cada extremo, donde se promedian menos datos. Después se calcularon las pruebas de Ljung-Box (10 lags), rachas, Spearman y Kruskal-Wallis a un nivel del 5 %.

5.3. Ajuste de curvas

Siguiendo el tutorial de Amat Rodrigo [2], en un notebook independiente se ajustaron por máxima verosimilitud las cinco distribuciones de la guía (Exponencial, Lognormal, Normal, Gamma y Beta) y cuatro adicionales: Weibull, Log-logística, Rayleigh y Gaussiana inversa. Se tomaron estas decisiones de modelado:

- Como los datos son tiempos no negativos, en las distribuciones con soporte $[0, \infty)$ se fijó $\text{loc} = 0$, de modo que no cuenta como parámetro libre (paso 1 de la estrategia de Banks: respetar los límites físicos).
- La Beta se ajustó en el rango observado $[\text{mín}, \text{máx}]$, ampliado en una fracción 10^{-6}. Como ese soporte sale de los datos, en rigor tendría cuatro parámetros; contarlo así solo empeoraría su AIC y BIC.
- La Normal se ajustó sin restricciones ($k = 2$).

Para cada conjunto se calcularon SSE, AIC y BIC, y se ordenaron las distribuciones por el promedio de sus puestos en los tres criterios, con el AIC como desempate. Las tres primeras se graficaron sobre el histograma. La mejor se verificó con P-P, Q-Q y Kolmogorov-Smirnov; en este caso el valor p es optimista porque los parámetros salen de los mismos datos. Para los conjuntos que no resultaron IID se ajustó un modelo de la dependencia o de la tendencia [1, Sec. 3.6].

6. Resultados y análisis

6.1. Estadística descriptiva

Cuadro 2: Descripción estadística de los conjuntos de datos A, B, C y D.

Medida estadística	Dataset A	Dataset B	Dataset C	Dataset D
Tamaño de la muestra	200	200	200	200
Mínimo	0,020964	$8{,}516 \times 10^{-5}$	0,92668	0,1115
Máximo	0,29897	1,5513	6669,9	17,967
Media	0,19504	0,20539	762,39	2,0605
Varianza	0,0019193	0,052481	$8{,}5217 \times 10^{5}$	5,413
Desviación estándar	0,04381	0,22909	923,13	2,3266
Percentil 25% (Q1)	0,16384	0,046329	152,91	0,63429
Percentil 50% (Q2, mediana)	0,19207	0,13768	455,56	1,4064
Percentil 75% (Q3)	0,23011	0,29018	1028,6	2,5289
Asimetría (skewness)	−0,28952	2,4064	2,4821	3,1596
Curtosis (exceso)	0,30901	7,9741	9,1009	14,089
Coef. de variación (s/media)	0,22462	1,1154	1,2108	1,1291

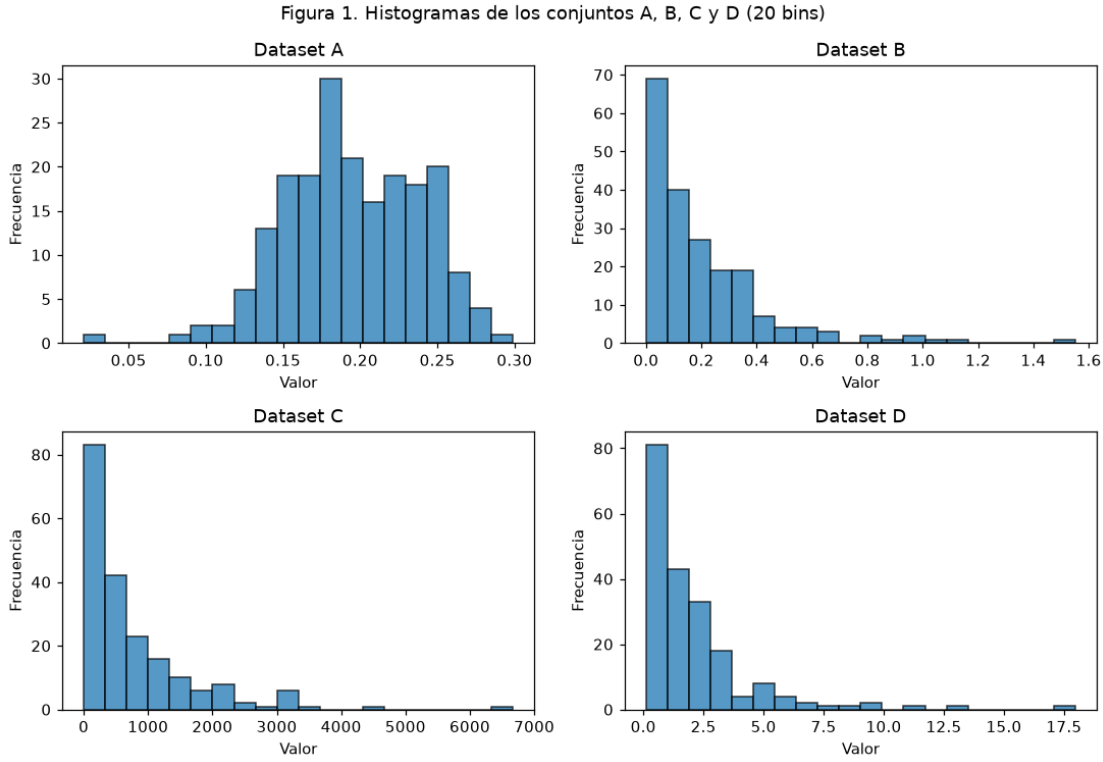


Figura 1: Histogramas de los conjuntos de datos A, B, C y D (20 bins).

¿Qué se puede analizar de las medidas descriptivas y los histogramas?

- **A** es el único conjunto casi simétrico: la media (0,195) y la mediana (0,192) casi coinciden, la asimetría es −0,29 y la variabilidad es baja ($CV = 0{,}22$). Los valores están acotados en

[0,021; 0,299] y el histograma tiene forma de campana, lo que apunta a una Normal o a una Gamma o Weibull con forma grande. El mínimo está aislado del resto.

- **B** tiene media 0,205 mayor que la mediana 0,138, asimetría 2,41 y $CV = 1{,}12 \approx 1$. La moda está en cero y la frecuencia decae de forma monótona: es el perfil de una exponencial.
- **C** tiene una escala muy distinta, de 0,93 a 6670. La media (762) supera mucho a la mediana (456), con asimetría 2,48, curtosis 9,1 y $CV = 1{,}21 > 1$: la cola derecha es más pesada que la de una exponencial.
- **D** tiene media 2,06 frente a mediana 1,41, asimetría 3,16 y la mayor curtosis (14,1), con $CV = 1{,}13$. El mínimo es positivo (0,11) y hay valores aislados de hasta 18. Una cola tan larga es típica de la Lognormal o la Log-logística.
- A y B tienen casi la misma media ($\approx 0{,}2$) pero distribuciones opuestas, así que la media y la varianza no bastan para elegir un modelo de entrada. Todos los conjuntos son positivos, lo que pone en duda la Normal para B, C y D, que tienen asimetría fuerte.

6.2. Análisis de independencia y estabilidad

Las Figuras 2 a 5 muestran las cinco gráficas pedidas para cada conjunto, más la serie de valores frente a su orden. La Tabla 3 resume las pruebas numéricas.

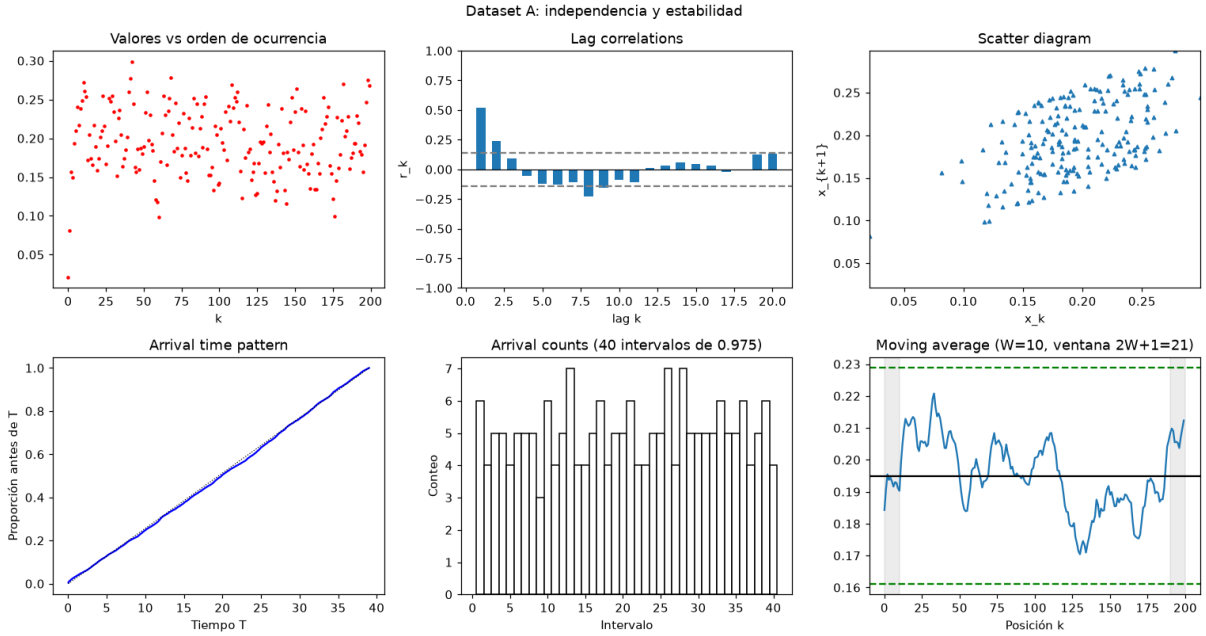


Figura 2: Dataset A: valores frente al orden, correlaciones de retraso, diagrama de dispersión, patrón de llegadas, conteos por intervalo y media móvil.

Dataset A: correlacionado y estacionario. Las correlaciones $r_1 = 0{,}517$ y $r_2 = 0{,}239$ están muy por encima de la banda y decaen con el retraso, como en un proceso autorregresivo; también hay valores negativos fuera de la banda en los lags 8 y 9. El diagrama de dispersión se inclina hacia la diagonal: a un valor alto le sigue otro alto. En cambio, el patrón de llegadas es prácticamente una recta, los conteos oscilan entre 3 y 7 sin tendencia y la media móvil se mantiene dentro de las bandas alrededor de 0,195. Sus oscilaciones son lentas, otra huella de la

correlación positiva. Los dos primeros valores (0,021 y 0,081) son bajos y la serie sube en pocos pasos, lo que sugiere un estado inicial del proceso.

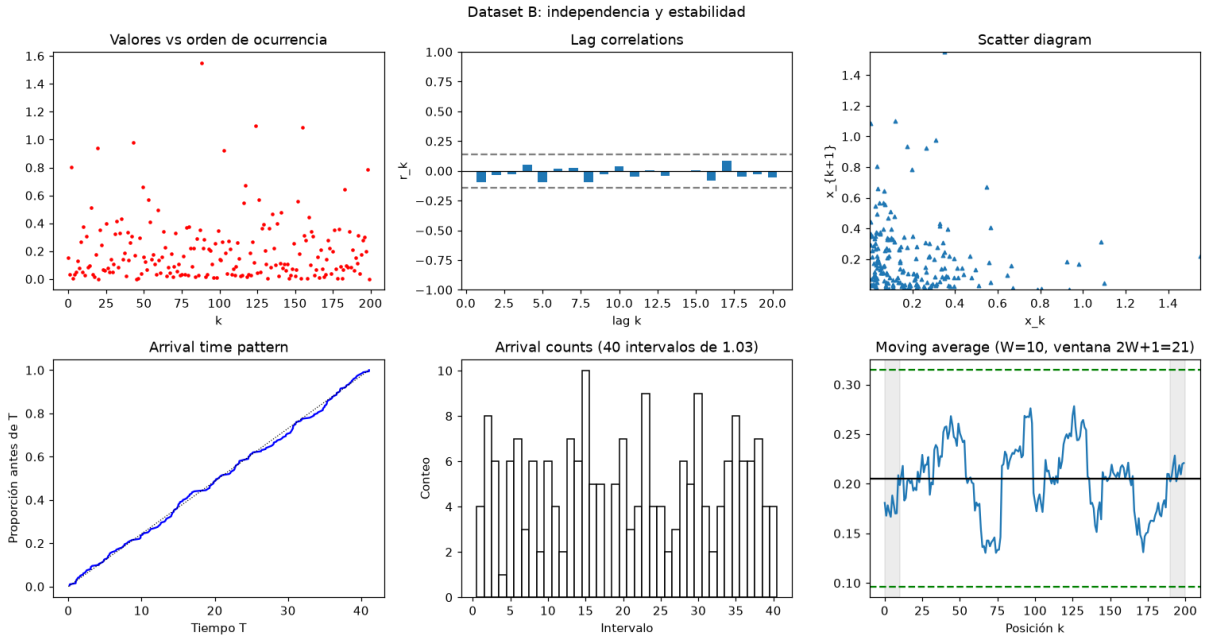


Figura 3: Dataset B: gráficas de independencia y estabilidad.

Dataset B: independiente y estacionario. Todas las correlaciones están dentro de la banda ($r_1 = -0{,}09$), con signos alternados y sin patrón. El diagrama de dispersión es una nube concentrada cerca del origen, con la forma de la marginal y sin inclinación. El patrón de llegadas sigue la diagonal, los conteos (0 a 10, media ≈ 5) tienen la dispersión esperable en un proceso de Poisson y la media móvil oscila entre 0,13 y 0,28 sin tendencia.

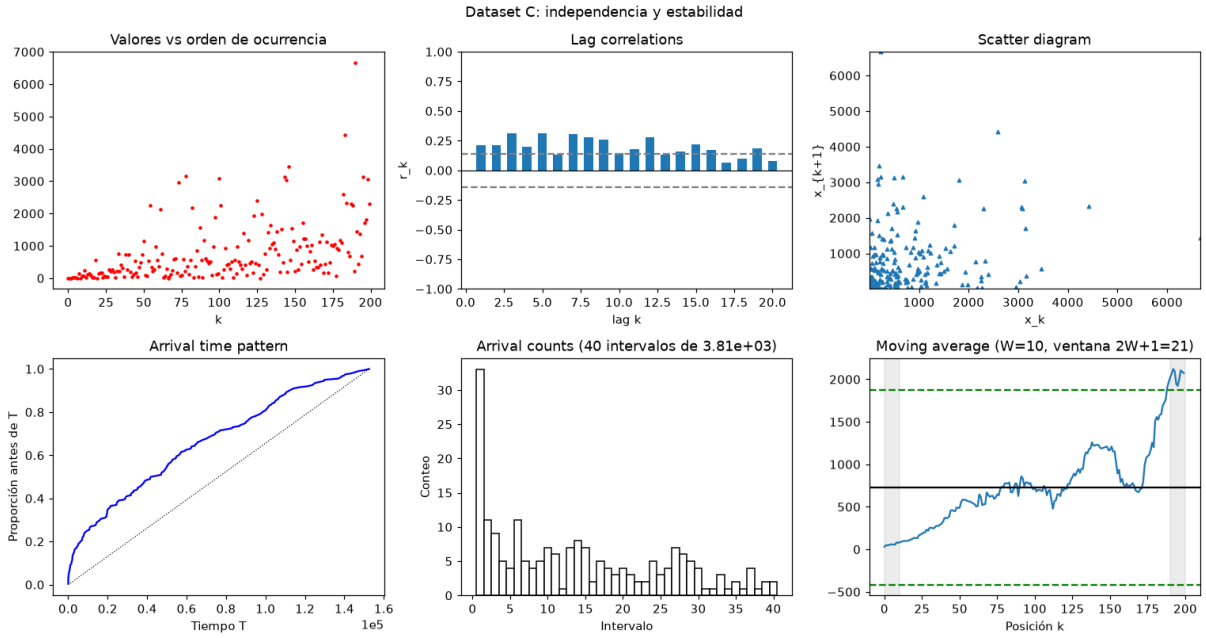


Figura 4: Dataset C: gráficas de independencia y estabilidad.

Dataset C: no estacionario. Los valores crecen con el orden de observación: los 20 primeros no pasan de 565 y los últimos llegan a miles. Todas las correlaciones son positivas y superan la banda hasta el lag 15 aproximadamente, sin decaer, que es el síntoma típico de una *tendencia* y no de una dependencia de corto plazo. El patrón de llegadas es una curva cóncava muy alejada de la diagonal: el 20 % de las llegadas ocurre en el 4 % del tiempo y la mitad en el 27 %. Los conteos pasan de 33 en el primer intervalo a entre 1 y 8 en los demás, y la media móvil sube casi sin pausa de 30 a 2100, saliéndose de las bandas al final.

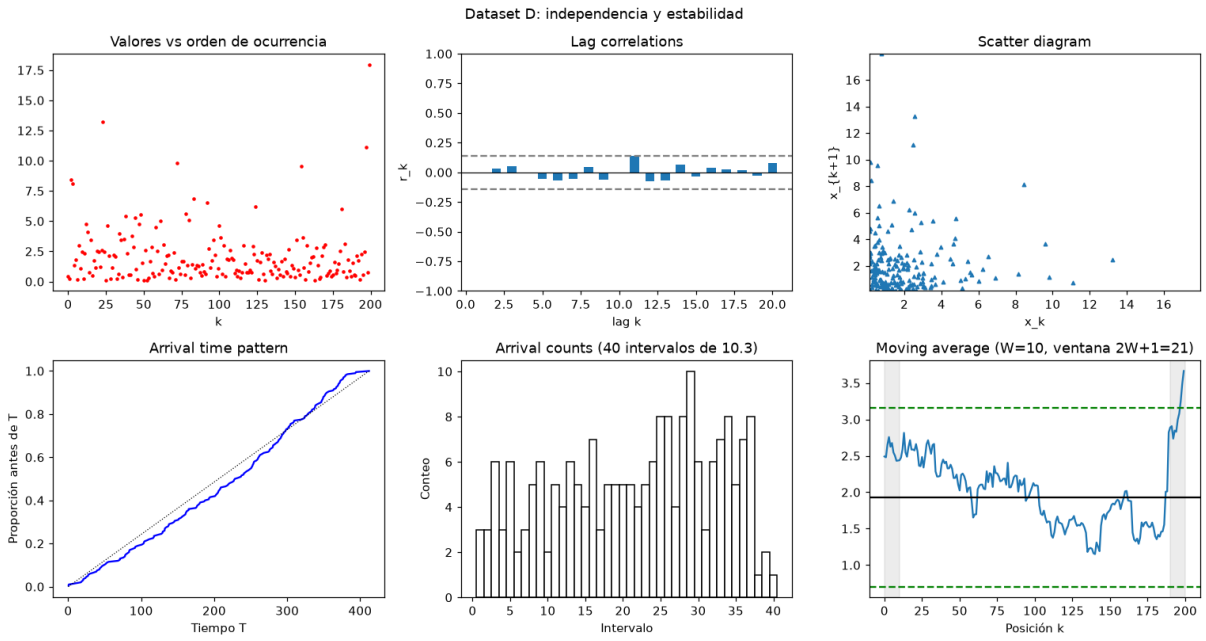


Figura 5: Dataset D: gráficas de independencia y estabilidad.

Dataset D: independiente, con estacionariedad aceptable. Las correlaciones están dentro de la banda ($r_1 = -0{,}003$) y el diagrama de dispersión no tiene inclinación. El patrón de llegadas queda algo por debajo de la diagonal en la primera mitad (llegadas un poco más lentas) y luego la cruza. Los conteos van de 2 a 10, algo más altos entre los intervalos 25 y 37. La media móvil baja suavemente de 2,6 a 1,5 y solo se sale de la banda en el extremo sombreado, donde pesan los valores 11,1 y 18,0, dos de los tres últimos de la serie. Esta deriva no es estadísticamente significativa.

Cuadro 3: Pruebas de independencia y estabilidad (valores p al nivel 5 %). LB: Ljung-Box con 10 lags; ρ_S: correlación de Spearman entre valor y orden; K-W: Kruskal-Wallis entre cuatro bloques de 50 datos.

	r_1	p LB	p rachas	ρ_S	p Spearman	p K-W	**Medias por bloque**
A	0,517	$4{,}99 \times 10^{-16}$	0,00111	−0,105	0,14	0,394	0,2015; 0,196; 0,189; 0,1937
B	−0,0925	0,686	0,0334	−0,00348	0,961	0,989	0,2172; 0,1927; 0,2109; 0,2008
C	0,21	$6{,}56 \times 10^{-22}$	0,0159	0,603	$3{,}21 \times 10^{-21}$	$7{,}96 \times 10^{-14}$	191; 644,1; 963,6; 1251
D	−0,00259	0,932	0,202	−0,117	0,0987	0,242	2,585; 1,981; 1,52; 2,156

Cuadro 4: Resumen de la evaluación de supuestos.

Dataset	**Independencia**	**Estabilidad**	**¿IID?**
A	No: $r_1 = 0{,}52$, LB y rachas rechazan	Sí: sin tendencia (p Spearman = 0,14)	No
B	Sí: p LB = 0,69	Sí: p Spearman = 0,96, p K-W = 0,99	Sí
C	No (efecto de la tendencia)	No: $\rho_S = 0{,}60$; medias por bloque de 191 a 1251	No
D	Sí: p LB = 0,93	Sí: deriva leve no significativa (p = 0,10)	Sí

¿Qué se puede determinar sobre la independencia y la estabilidad? Solo B y D cumplen los supuestos IID y admiten directamente una distribución univariada. A es estacionario pero correlacionado, así que generar valores independientes de su distribución marginal haría perder la persistencia de la serie, y eso afecta, por ejemplo, la formación de colas. C no es estacionario: su distribución cambia con el tiempo y un único modelo para todos los datos mezcla escalas distintas. La prueba de rachas de B ($p = 0{,}033$) es un resultado aislado: ninguna correlación sale de la banda y Ljung-Box no rechaza, y con cuatro pruebas por conjunto al 5 % es esperable algún rechazo por azar.

6.3. Ajuste de curvas y bondad de ajuste

Las Tablas 5 a 8 presentan los parámetros estimados y los criterios para las nueve distribuciones, en el orden de la guía. En negrita aparece el mejor valor de cada criterio, y la última columna da el puesto en el ranking combinado. Los parámetros siguen la convención de `scipy.stats`: *escala* es la media en la Exponencial y $e^{\mu_{\ln}}$ en la Lognormal, σ es la desviación estándar de $\ln X$, a y c son parámetros de forma, y loc = 0 se omite.

Cuadro 5: Bondad de ajuste para el conjunto de datos A.

Distribución	Parámetros	SSE	AIC	BIC	Puesto
Exponencial	escala = 0,195	340,5	−251,82	−248,52	9
Lognormal	σ = 0,275, escala = 0,189	36,97	−611,09	−604,49	5
Normal	loc = 0,195, escala = 0,0437	29,15	**−680,59**	**−673,99**	1
Gamma	a = 16,18, escala = 0,01206	**28,24**	−647,34	−640,75	3
Beta	a = 2,862, b = 1,798, loc = 0,02096, escala = 0,278	59,26	−597,26	−590,66	6
Weibull	c = 5,071, escala = 0,212	32,43	−679,36	−672,76	2
Log-logística	c = 7,293, escala = 0,1927	33,42	−655,44	−648,85	4
Rayleigh	escala = 0,1413	185,2	−497,00	−493,70	8
Gaussiana inversa	μ = 0,08962, escala = 2,176	48,06	−583,42	−576,83	7

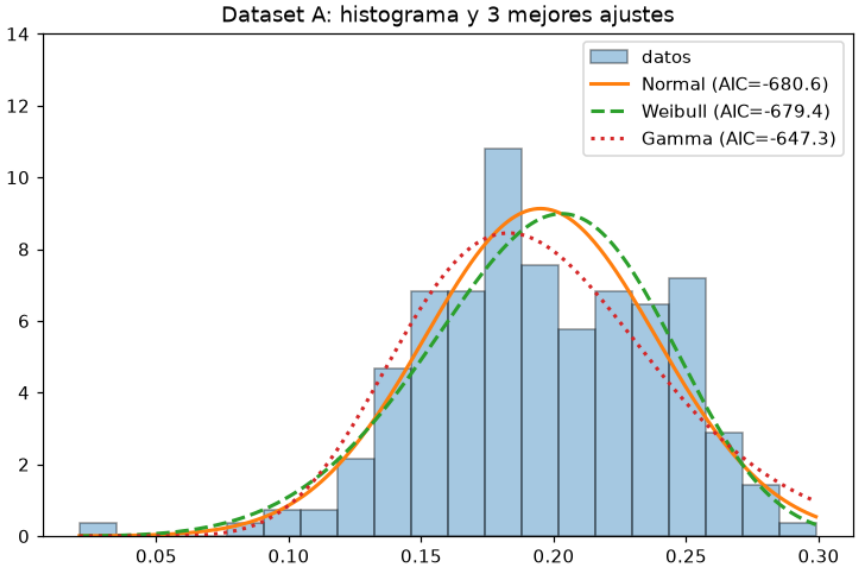


Figura 6: Dataset A: histograma y las tres distribuciones con mejor ajuste.

Dataset A. La Normal gana en AIC y BIC, con la Weibull ($c = 5{,}07$) muy cerca ($\Delta\text{AIC} = 1{,}2$). La Gamma tiene el menor SSE, pero su AIC es 33 puntos peor. La Exponencial y la Rayleigh quedan últimas porque no pueden representar una campana alejada de cero. La Normal asigna una probabilidad de solo $4 \cdot 10^{-6}$ a valores negativos, así que en la práctica no viola el límite físico. Mejores tres: **Normal, Weibull y Gamma**.

Cuadro 6: Bondad de ajuste para el conjunto de datos B.

Distribución	Parámetros	SSE	AIC	BIC	Puesto
Exponencial	escala = 0,2054	0,4358	−231,13	**−227,83**	3
Lognormal	$\sigma = 1{,}437$, escala = 0,104	2,326	−188,73	−182,14	5
Normal	loc = 0,2054, escala = 0,2285	11,57	−18,89	−12,29	7
Gamma	$a = 0{,}8636$, escala = 0,2378	0,3158	−232,10	−225,50	2
Beta	$a = 0{,}5585$, $b = 2{,}72$, loc $= 8{,}361 \times 10^{-5}$, escala = 1,551	2,534	−169,24	−162,64	6
Weibull	$c = 0{,}9095$, escala = 0,1963	**0,2762**	**−232,26**	−225,67	1
Log-logística	$c = 1{,}307$, escala = 0,1184	1,143	−206,65	−200,06	4
Rayleigh	escala = 0,2173	18,12	85,99	89,29	8
Gaussiana inversa	$\mu = 22{,}4$, escala = 0,009169	6,528	151,99	158,58	9

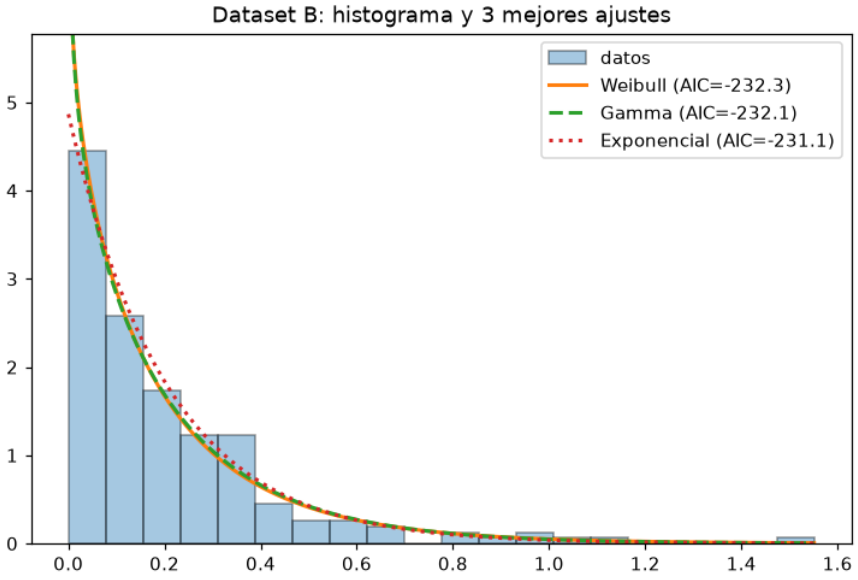


Figura 7: Dataset B: histograma y las tres distribuciones con mejor ajuste.

Dataset B. La Weibull ($c = 0{,}91$), la Gamma ($a = 0{,}86$) y la Exponencial (media 0,205) tienen AIC en un rango de 1,1 puntos. La Weibull gana en SSE y AIC, y la Exponencial en BIC, porque usa un parámetro menos. Las dos formas estimadas están cerca de 1, que es justo el caso en que Weibull y Gamma se reducen a la Exponencial. Mejores tres: **Weibull, Gamma y Exponencial**.

Cuadro 7: Bondad de ajuste para el conjunto de datos C.

Distribución	Parámetros	SSE	AIC	BIC	Puesto
Exponencial	escala = 762,4	$5{,}978 \times 10^{-8}$	3056,59	3059,88	3
Lognormal	$\sigma = 1{,}648$, escala = 324,3	$6{,}361 \times 10^{-8}$	3084,19	3090,78	5
Normal	loc = 762,4, escala = 920,8	$9{,}265 \times 10^{-7}$	3301,68	3308,28	7
Gamma	$a = 0{,}7062$, escala = 1080	$4{,}493 \times 10^{-8}$	**3040,22**	**3046,82**	1
Beta	$a = 0{,}4714$, $b = 2{,}635$, loc = 0,92, escala = 6669	$2{,}538 \times 10^{-7}$	3092,86	3099,45	6
Weibull	$c = 0{,}8007$, escala = 676	$\mathbf{2{,}524 \times 10^{-8}}$	3040,81	3047,41	2
Log-logística	$c = 1{,}126$, escala = 384,4	$4{,}076 \times 10^{-8}$	3072,48	3079,08	4
Rayleigh	escala = 845,3	$1{,}434 \times 10^{-6}$	3481,09	3484,39	9
Gaussiana inversa	$\mu = 19{,}81$, escala = 38,49	$3{,}224 \times 10^{-7}$	3310,51	3317,11	8

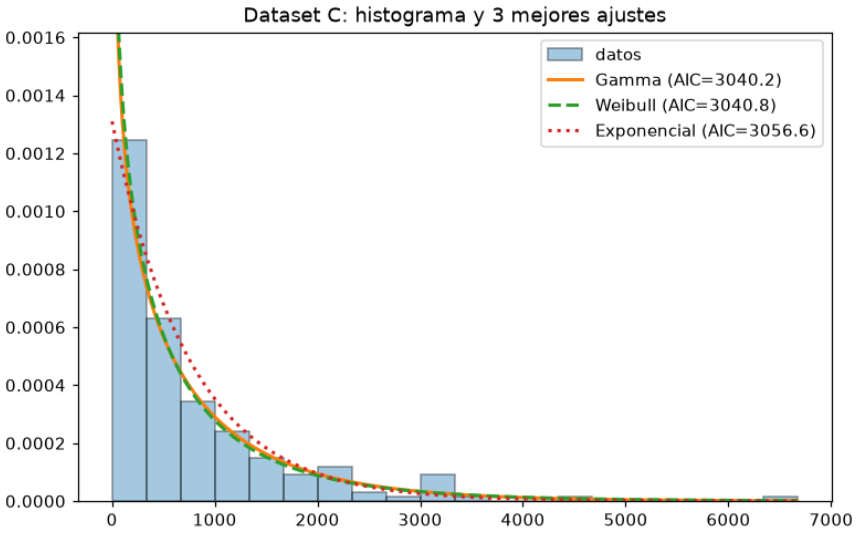


Figura 8: Dataset C: histograma y las tres distribuciones con mejor ajuste.

Dataset C. La Gamma ($a = 0{,}71$) y la Weibull ($c = 0{,}80$) empatan en la práctica ($\Delta\text{AIC} = 0{,}6$), y la Exponencial queda tercera ($\Delta\text{AIC} = 16$). Las formas menores que 1 reflejan una variabilidad mayor que la exponencial ($CV = 1{,}21$). Ese exceso se explica por la no estacionariedad: mezclar exponenciales con medias distintas produce una distribución con $CV > 1$. El SSE es del orden de 10^{-8} porque la densidad de una variable con escala de miles es muy pequeña, así que no es comparable entre conjuntos. Mejores tres: **Gamma, Weibull y Exponencial**.

Cuadro 8: Bondad de ajuste para el conjunto de datos D.

Distribución	Parámetros	SSE	AIC	BIC	Puesto
Exponencial	escala = 2,06	0,009898	691,18	694,48	4
Lognormal	$\sigma = 1{,}019$, escala = 1,273	0,006913	**675,89**	**682,49**	1
Normal	loc = 2,06, escala = 2,321	0,1175	908,33	914,93	8
Gamma	$a = 1{,}178$, escala = 1,749	0,01048	689,97	696,56	5
Beta	$a = 0{,}5489$, $b = 3{,}092$, loc = 0,1115, escala = 17,86	0,03516	755,55	762,15	7
Weibull	$c = 1{,}042$, escala = 2,099	0,01066	692,55	699,14	6
Log-logística	$c = 1{,}705$, escala = 1,31	**0,006011**	681,40	688,00	2
Rayleigh	escala = 2,194	0,1572	934,06	937,36	9
Gaussiana inversa	$\mu = 1{,}763$, escala = 1,169	0,02549	685,40	692,00	3

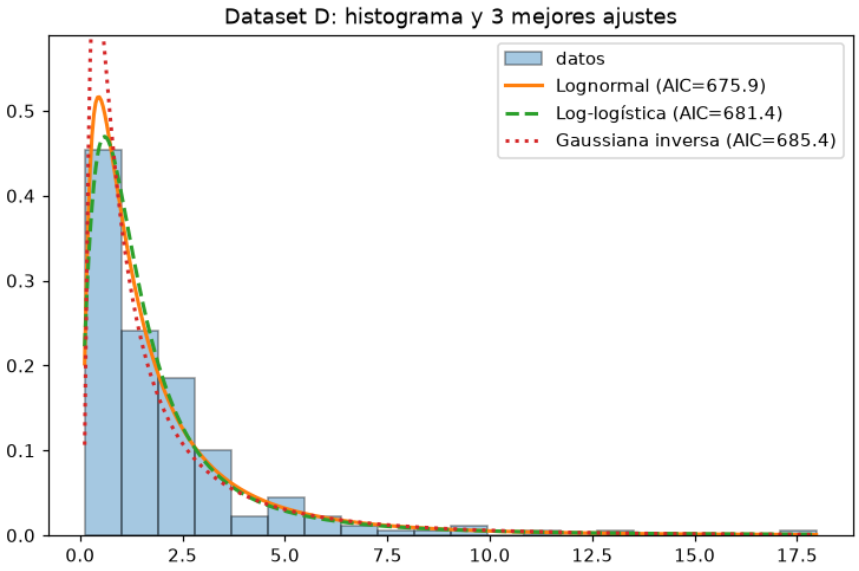


Figura 9: Dataset D: histograma y las tres distribuciones con mejor ajuste.

Dataset D. La Lognormal gana en AIC y BIC. Sus parámetros equivalen a que $\ln X$ siga una $N(0{,}241;\ 1{,}019^2)$. La Log-logística tiene el menor SSE y queda segunda ($\Delta\text{AIC} = 5{,}5$). La Gaussiana inversa es tercera: empata en el ranking con la Exponencial, pero la supera en AIC y BIC. Las tres tienen moda positiva y cola derecha larga, como el histograma. Mejores tres: **Lognormal, Log-logística y Gaussiana inversa**.

Verificación del mejor modelo. En los cuatro conjuntos, los gráficos P-P quedan pegados a la diagonal (Figuras 10 y 11), y Kolmogorov-Smirnov no rechaza el mejor modelo: $p = 0{,}63$ (A), 0,96 (B), 0,91 (C) y 0,59 (D). En el Q-Q de A, el primer dato (0,021) queda muy por debajo del modelo, y la cola derecha de los datos es algo más corta que la normal. En el de D, la Lognormal predice extremos algo mayores que los observados: al máximo, 18,0, le corresponde un cuantil teórico de ≈ 22. Para B, la razón de verosimilitudes **no rechaza** que la forma sea 1: Exponencial frente a Weibull, $p = 0{,}077$, y frente a Gamma, $p = 0{,}085$. El buen K-S de C solo indica que la distribución agregada se parece a una Gamma; no valida el supuesto IID, que ya falló.

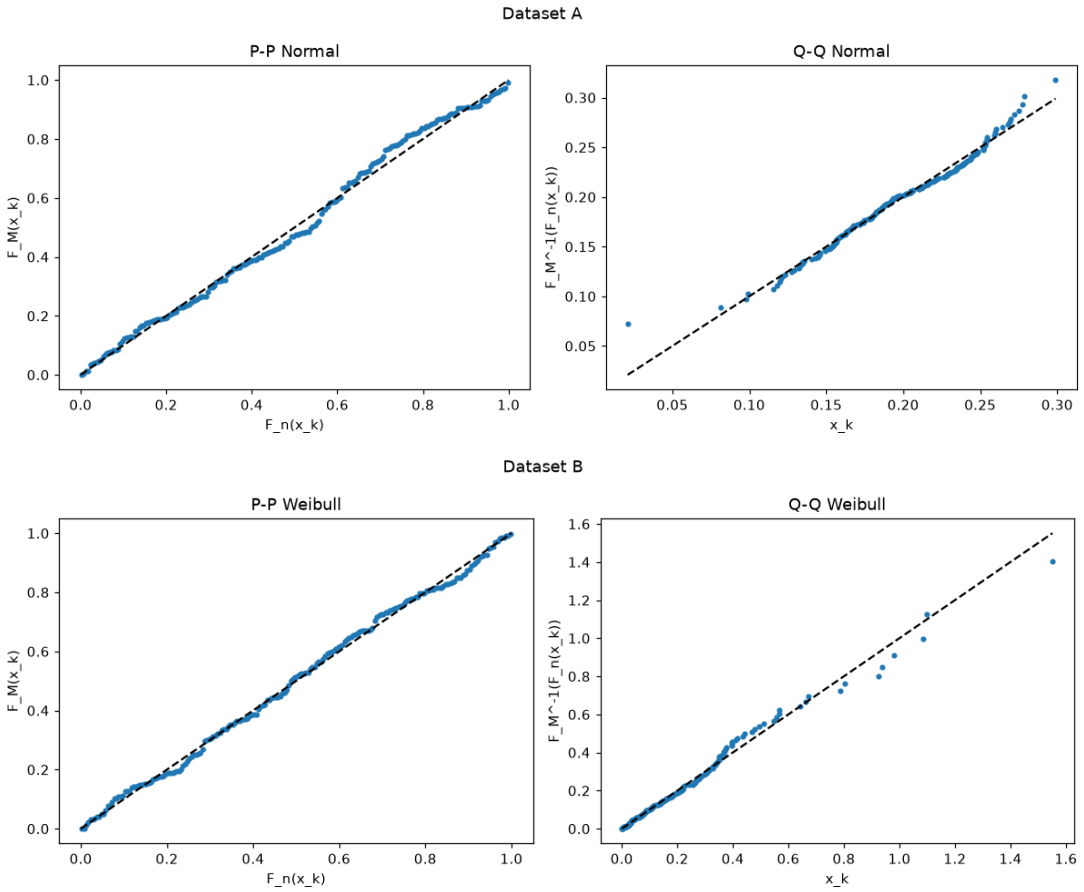


Figura 10: Gráficos P-P y Q-Q del mejor modelo para los conjuntos A (Normal) y B (Weibull).

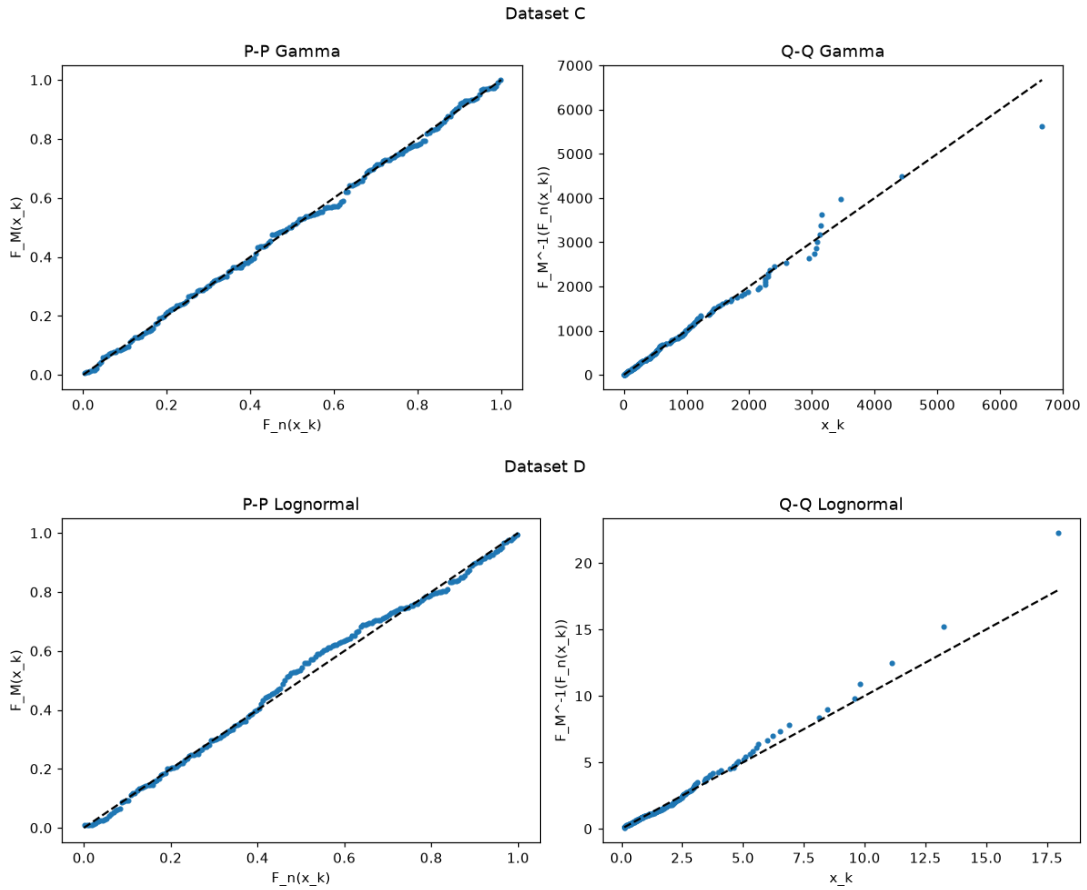


Figura 11: Gráficos P-P y Q-Q del mejor modelo para los conjuntos C (Gamma) y D (Lognormal).

6.4. Modelos para los conjuntos no IID

Dataset A: AR(1). Con $\hat{\mu} = 0{,}195$ y $\hat{\varphi} = r_1 = 0{,}517$, los residuos $\varepsilon_k = (x_k - \hat{\mu}) - \hat{\varphi}(x_{k-1} - \hat{\mu})$ ya no están correlacionados (Ljung-Box $p = 0{,}29$). Sin embargo, *no son normales*: tienen curtosis $-1{,}24$ y un rango cerrado de $\pm 0{,}06$, que es la firma de una uniforme. El ajuste $U(-0{,}060;\, 0{,}061)$ tiene K-S $p = 0{,}73$ y un AIC 81 puntos mejor que el de la normal. El modelo de entrada es entonces

$$X_k = 0{,}195 + 0{,}517\,(X_{k-1} - 0{,}195) + \varepsilon_k, \qquad \varepsilon_k \sim U(-0{,}060;\, 0{,}061). \tag{3}$$

Su marginal es una suma ponderada de uniformes, casi normal pero de colas cortas, lo que coincide con el Q-Q de la Normal.

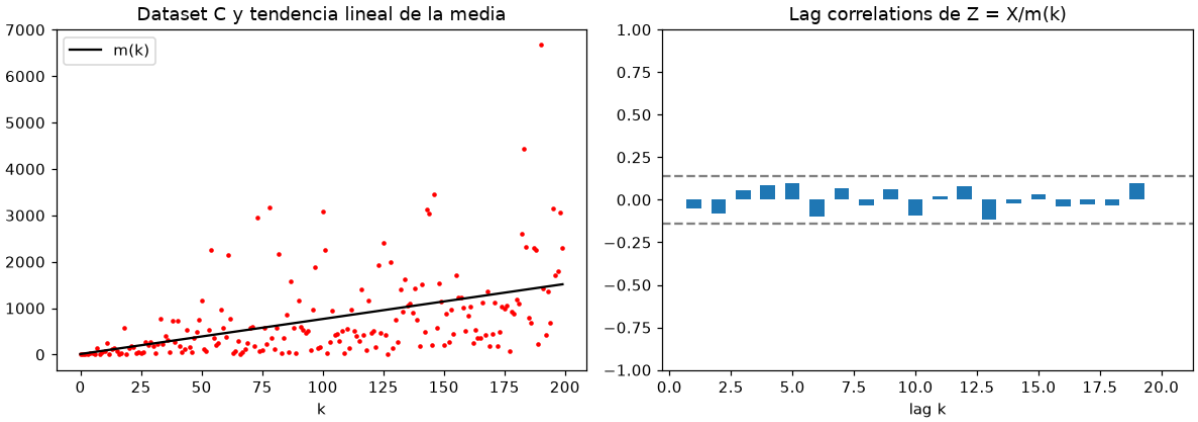


Figura 12: Dataset C: tendencia lineal de la media (izquierda) y correlaciones de retraso de los datos normalizados $Z_k = X_k/m(k)$ (derecha).

Dataset C: media con tendencia. La recta de mínimos cuadrados $m(k) = 10{,}82 + 7{,}553\,k$ tiene pendiente significativa ($p \approx 10^{-12}$). Los datos normalizados $Z_k = X_k/m(k)$ son IID (Figura 12): $r_1 = -0{,}05$, Ljung-Box $p = 0{,}30$ y Kruskal-Wallis $p = 0{,}87$. Además son exponenciales: $CV = 1{,}04$, la Exponencial gana en AIC y BIC, la Gamma y la Weibull estimadas tienen forma ≈ 1 ($a = 1{,}03$, $c = 1{,}01$) y K-S da $p = 0{,}84$. Es decir, C son tiempos entre llegadas exponenciales con media creciente: un proceso de llegadas cuya tasa disminuye con el tiempo.

6.5. Selección de la distribución

Cuadro 9: Distribución seleccionada y modelo de entrada recomendado por conjunto de datos.

Dataset	Distribución (top 3)	Modelo para la simulación
A	Normal($\mu = 0{,}195$; $\sigma = 0{,}0437$)	AR(1): $\varphi = 0{,}517$, $\varepsilon \sim U(-0{,}060;\ 0{,}061)$
B	Exponencial(media 0,2054)	IID Exponencial (tasa 4,87)
C	Exponencial con media variable	$X_k = m(k)\,Z_k$, $m(k) = 10{,}82 + 7{,}553\,k$, $Z \sim$ Exp(media 0,988)
D	Lognormal($\sigma = 1{,}019$; escala 1,273)	IID Lognormal

¿Cuál de las tres distribuciones con mejor ajuste se selecciona y por qué?

- **A: Normal.** Gana en AIC y BIC, respeta en la práctica el rango de los datos y su Q-Q es muy bueno en el centro. La Weibull es casi equivalente, pero la Normal es más simple de interpretar y es la marginal natural de un proceso autorregresivo. Como A está correlacionado, en la simulación no deben generarse valores independientes de la Normal, sino el AR(1).
- **B: Exponencial.** Se elige por parsimonia: tiene el mejor BIC, la razón de verosimilitudes no justifica el parámetro de forma de la Weibull o la Gamma ($p > 0{,}07$) y la diferencia de AIC es de solo 1,1. Además es coherente con 5.2: datos IID con patrón de llegadas lineal, es decir, llegadas de Poisson.
- **C: Exponencial, con media variable en el tiempo.** Entre las tres mejores, la Gamma ajusta mejor los datos agregados, pero solo porque mezcla tramos con escalas distintas.

Al quitar la tendencia, la Exponencial es la mejor distribución, y es la que debe usarse combinada con $m(k)$. Si solo se quisiera reproducir la distribución agregada de estos 200 datos, se usaría la Gamma ($a = 0{,}706$; escala 1080).

- **D: Lognormal.** Es la mejor en AIC y BIC ($\Delta\text{AIC} = 5{,}5$ frente a la Log-logística), los datos son IID, y P-P, Q-Q y K-S no muestran problemas. Su cola algo más pesada que la de los datos es conservadora en un estudio de simulación.

7. Conclusiones

- La estadística descriptiva orienta la elección de familias candidatas: la asimetría y el coeficiente de variación separaron de inmediato el conjunto simétrico (A) de los tres con cola derecha (B, C y D). Sin embargo, no detecta dependencia ni tendencias.
- Las gráficas de 5.2 y las pruebas numéricas son indispensables antes de ajustar: dos de los cuatro conjuntos no son IID. A está autocorrelacionado ($r_1 = 0{,}52$) y C tiene una tendencia creciente en la media.
- Un buen ajuste de la distribución marginal no valida el supuesto IID. En C, la Gamma pasa K-S con $p = 0{,}91$, pero el proceso real son exponenciales con media creciente; usar la Gamma con valores independientes no reproduciría su evolución en el tiempo.
- SSE, AIC y BIC suelen coincidir, pero no siempre. El SSE depende de los bins y de la escala, y el AIC y el BIC penalizan los parámetros. Cuando las diferencias son pequeñas, conviene preferir el modelo más simple, apoyándose en pruebas como la razón de verosimilitudes (Exponencial en B).
- Los modelos recomendados son: AR(1) con innovaciones uniformes para A, Exponencial IID para B, Exponencial con media lineal en el tiempo para C y Lognormal IID para D.

Referencias

[1] J. Banks (ed.), *Handbook of Simulation: Principles, Methodology, Advances, Applications, and Practice*. John Wiley & Sons, 1998, cap. 3.

[2] J. Amat Rodrigo, *Ajuste y selección de distribuciones con Python*, 2021, licencia CC BY-NC-SA 4.0. https://www.cienciadedatos.net/documentos/pystats01-ajuste-distribuciones-python.html. DOI: 10.5281/zenodo.10006330.

[3] P. Virtanen et al., "SciPy 1.0: fundamental algorithms for scientific computing in Python", *Nature Methods*, 17, 261–272, 2020.